
캘리포니아 집 값 예측 분석

1. 개요

본 분석의 목적은 캘리포니아의 인구 통계 및 지리적 특성 데이터를 활용하여 주택 가격 중앙값(MedHouseVal)을 예측하는 회귀 모델을 구축하는 것이다. 다중회귀분석을 통해 데이터셋에 포함된 다차원 변수들이 집값에 미치는 영향을 파악하고, Ridge와 Lasso의 규제 회귀 모델을 적용하여 다중회귀분석과의 차이를 비교하였다.

2. 데이터셋 구성

데이터셋은 총 20,640개의 샘플과 8개의 독립변수 그리고 1개의 타겟변수로 구성되어있다. 데이터셋의 변수에 대한 설명은 아래와 같다.


변수구분	변수명	변수 설명
독립변수	MedInc	블록 그룹 내 가구 소득의 중앙값
	HouseAge	블록 그룹 내 주택 연령의 중앙값
	AveRooms	가구당 평균 방 개수
	AveBedrms	가구당 평균 침실 수
	Population	블록 그룹 내 인구
	AveOccup	가구당 평균 주거 인원
	Latitude	위도
	Longitude	경도
타겟변수	MedHouseVal	블록 그룹 내 주택 가격의 중앙값(10만달러)

3. 탐색적 데이터 분석 (EDA) (부록 7.1 참조)

결측치 및 데이터 유형 확인 : 데이터 확인 결과 모든 변수에서 결측치가 존재하지 않음을 확인하였다. 또한 모든 데이터가 연속형 float64 수치형 변수임을 확인하였다.

단일 변수 분석 및 이상치 탐색 :

- 타겟 변수 상한 : MedHouseVal(주택 가격) 변수의 히스토그램 확인 결과 5.0 초과 값들이 모두 5.00001로 일괄 기록되어 있음을 확인하였다.
- 주택 연령 상한 : HouseAge(주택 연령) 변수의 히스토그램 확인 결과 52년 이상의 오래된 주택들의 값들이 모두 52로 일괄 기록되어 있음을 확인하였다.
- 비현실적 극단치 : AveRooms(평균 방 개수), AveOccup(평균 주거 인원), AveBedrms(평균 침실 개수) 변수들의 박스플롯 확인 결과 각각 140, 30, 1200 이상에 달하는 비현실적 혹은 일반적이지 않은 극단적인 이상치가 관찰되었다. 이는 데이터 수집 과정에서 블록 내 특이 주거 형태의 값들이 포함되었거나 잘못 입력된 값으로 판단된다.




변수 간 상관관계 및 다중공선성 :

- 타겟 변수와의 관계 : 상관관계 매트릭스 확인 결과 MedInc(소득 중앙값) 변수가 MedHouseVal(주택 가격)과 상관관계수 0.69로 집값 예측하는데에 가장 중요한 지표임을 확인하였다.
- 다중공선성 : AveRooms(평균 방 개수)와 AveBedrms(평균 침실 개수)의 상관관계수가 매우 높게 나타났다.

지리적 공간 데이터 분석 : Latitude(위도)와 Longitude(경도) 변수를 이용하여 지도 시각화를 통해 지리적 인사이트를 도출하였다.

- 해안선 프리미엄 : 위도와 경도가 작아질수록 특히 서남부 해안선 근처로 갈수록 높은 가격의 집들이 모여있음을 확인하였다.
- 핫스팟 조명 : 지도 시각화 결과 로스앤젤레스, 샌디에고, 실리콘밸리, 샌프란시스코 등 주요 해안 거점을 중심으로고가 주택이 밀집되어 있음을 확인하였다. 이들은 캘리포니아의 주요 해안 대도시로 단순 위도와 경도 좌표로는 이 지리적 프리미엄을 설명하기 어려움을 확인하였다.



부가적인 히스토그램과 박스플롯 등의 전처리 수행 전 EDA 결과에 대하여서는 부록 7.1에서 확인할 수 있다.

4. 데이터 전처리 (전처리 이후 EDA 결과 부록 7.2 참조)

전처리 과정은 탐색적 데이터 분석을 통해 발견된 데이터의 한계 및 모순을 보완하고, 선형 회귀 모델의 예측 성능을 올리기 위해 수행하였다.

데이터 정제 및 이상치 처리 :

- 상한 데이터 제거 : MedHouseVal(주택 가격)과 HouseAge(주택 연령) 변수에는 특정 수치 이상을 일괄적인 값으로 통일한 왜곡이 존재하였다. 모델이 이 한계값을 자연스러운 패턴으로 학습하는 것을 방지하기 위해 $HouseAge < 52$ 및 $MedHouseVal \leq 5.0$ 인 데이터만 남기고 필터링을 수행하였다.
- 극단적 이상치 통제 : AveRooms(평균 방 개수)와 AveOccup(평균 주거 인원)에 존재하는 비정상적인 극단치를 제거하기 위해 사분위수 범위 기반 필터링을 적용하였다. 이때 박스플롯 확인 결과 데이터의 분포가 둘 다 오른쪽으로 매우 긴 꼬리를 가지는 비대칭을 가지고 있으므로 정상 데이터 손실을 최소화하면서 극단치를 선택적으로 배제하기 위해 IQR의 3배를 상하한으로 설정하였다.
- 논리적 모순 데이터 정제 : AveBedrms(평균 침실 개수) 변수의 값이 AveRooms(평균 방 개수) 변수의 값보다 큰 경우는 물리적으로 불가능하다. $AveBedrms \leq AveRooms$ 조건식을 적용하여 AveBedrms가 더 큰 경우의 행은 제거하였고, 극단적인 이상치를 통제한 AveRooms를 통하여 AveBedrms의 이상치도 통제하였다.

파생 변수 생성(Feature Engineering) :

- 공간 상호작용 변수(lon_lat_mul) : Latitude(위도)와 Longitude(경도)를 단순한 독립된 개별 변수로 두지 않고 두 값을 곱한 파생 변수를 추가하였다. 이는 선형 모델이 두 지리적 변수가 결합하여 만들어내는 비선형적이고 복합적인 위치 효과를 학습할 수 있도록 하기 위함이다.
- 핫스팟 거점 접근성 변수(dist_to_coast) : 캘리포니아 주택 가격의 핵심 결정 요인인 해안선 프리미엄을 수치화하였다. 샌프란시스코, 로스앤젤레스, 샌디에고의 주요 해안 대도시의 위경도 좌표를 기준하여, 각 주택 구역에서 가장 가까운 해안 도시까지의 유클리드 거리를 계산해 새로운 독립 변수로 추가하였다.

이러한 전처리 과정을 거친 이후, 데이터셋은 총 18,285개의 샘플과 10개의 독립변수 그리고 1개의 타겟변수를 포함하였다.

데이터 분할 및 스케일링 :

- 데이터분할 : train 데이터셋과 test 데이터셋으로 나누었고, train과 test를 7:3의 비율로 분리하였다.
- 로그 스케일링 : Population(인구 수) 변수는 지역 특성을 가지고 있는 heavy tailed 분포에 가깝다고 판단하여 이상치 제거 대신 로그 스케일링을 적용하였다. Dist_to_coast 변수와 MedInc(소득 중앙값) 변수는 로그 스케일링 시 예측능력이 떨어지는 효과가 발생하여 로그 스케일링 하지 않았다.
- Robust Scaler 적용 : 앞선 전처리 과정에서 IQR 정제를 통하여 극단적인 이상치는 제거하였으나, 데이터 분포가 여전히 완전한 정규분포는 아니다. 이러한 이유로 이상치에 덜 민감한 중앙값과 사분위수를 활용하는 Robust Scaler를 적용하였다.

전처리 이후 EDA 결과에 대해서는 부록 7.2에서 확인할 수 있다.

5. 모델링 (부록 7.3 참조)

다중선형회귀(OLS)와 Ridge, Lasso의 규제 회귀 모델을 적용하여 성능을 비교 분석하였다.

- 다중선형회귀 (OLS)

별도의 하이퍼파라미터 튜닝 없이 오차제곱합을 최소화하는 방향으로 학습을 진행하였다.

학습 결과 lon_lat_mul(위경도 곱)과 Latitude(위도)의 계수가 각각 9.5346과 6.1832로 집값 상승을 견인하는 강력한 요인으로 나타났다. 반면, Longitude(경도)의 계수가 -3.2148로 집값을 하락시키는 주요 요인으로 확인되었다.

- Ridge Regression

그리드 서치를 활용하여 5-Fold 교차검증을 수행하며 최적의 규제 파라미터를 찾기 위한 탐색을 하였다. 탐색 범위는 0.0001부터 100까지 설정하였다.

그리드 서치 결과 최적의 규제 파라미터는 0.0001로 산출되었으며, 0에 수렴하여 결과적으로 규제가 거의 들어가지 않았다. 변수의 계수 또한 OLS와 크게 차이가 나지 않았다.

학습 결과 lon_lat_mul(위경도 곱)과 Latitude(위도)의 계수가 각각 9.5294과 6.1791로 집값 상승을 견인하는 강력한 요인으로 나타났다. 반면, Longitude(경도)의 계수가 -3.2137로 집값을 하락시키는 주요 요인으로 확인되었다.

- Lasso Regression

그리드 서치를 활용하여 5-Fold 교차검증을 수행하며 최적의 규제 파라미터를 찾기 위한 탐색을 하였다. 탐색 범위는 0.0001부터 100까지 설정하였다.

그리드 서치 결과 최적의 규제 파라미터는 0.0001로 산출되었으며, 0에 수렴하였다. 하지만 L1 규제의 특성상 변수 계수에 변화가 있었고, 집값 예측의 주요 변수에 OLS 및 Ridge Regression과 차이가 확인되었다.

학습 결과 lon_lat_mul(위경도 곱)의 계수가 1.5284로 집값 상승을 견인하는 강력한 요인으로 나타났다. 그리고 Longitude(경도)의 계수가 -1.4952로 집값을 하락시키는 주요 요인으로 확인되었다. 반면, 앞선 모델과 달리 Lasso 모델에서는 Latitude(위도) 변수의 계수가 0이 되었고, 이 변수 대신 MedInc(소득 중앙값) 변수의 계수가 0.8659로 집값 상승을 견인하는 강력한 요인으로 나타났다.

OLS과 Ridge 모델에서도 MedInc(소득 중앙값) 변수가 각각 상승과 하락을 견인하는 주요 세 변수 이외 타 변수에 비해서는 집값 변동 즉 상승 방향으로 많은 영향을 주었으나 Lasso 모델과 달리 주요 변수의 역할은 하지 못하였다.

- 3개 모델 성능 종합 비교

평가 지표	OLS	RIDGE ($\Lambda=0.0001$)	LASSO ($\Lambda=0.0001$)
MAE	0.4275	0.4275	0.4283
MSE	0.3333	0.3333	0.3350
RMSE	0.5773	0.5773	0.5788
MAPE	0.2718	0.2718	0.2706
R^2	0.6416	0.6416	0.6397

성능 비교 이외 모델 결과 피쳐 중요도와 계수 정보는 부록 7.3에서 확인할 수 있다.

6. 결과 해석

캘리포니아 주택 가격 데이터셋을 활용하여 기초적인 OLS와 규제 회귀 모델을 모델링하고 그 성능을 비교 분석하였다. 도출된 결과와 평가지표를 종합하여 다음과 같은 분석적 시사점을 도출하였다.

- 규제의 무효성 :

가장 특징적 결과는 Ridge와 Lasso 모델 모두 최적의 규제 파라미터가 0.0001로 0에 수렴하였으며, 최종 평가 지표가 OLS와 거의 유사했다는 점이다. 규제 강도가 0에 수렴함은 현재 OLS 모델이 과적합 상태가 아님을 보여주며, 데이터 전처리 과정이 데이터의 노이즈를 잘 통제하였으므로 해석할 수 있다.

- 위도와 경도의 지리적 변수의 강력한 영향 :

OLS와 두 규제 모델 모두에서 지리적 위치와 관련된 변수들이 강력한 집값 예측의 주요 요인으로 확인되었다.

OLS와 Ridge 모델은 Longitude(경도)와 Latitude(위도) 그리고 파생변수인 lon_lat_mul(위경도 곱)이 집값 예측의 강력한 주요 변수로 확인되었고, Lasso에서도 Longitude(경도)와

lon_lat_mul(위경도 곱)이 주요 변수로 확인되었다.

이를 통하여 해안선 프리미엄이라는 캘리포니아의 지역적 특성이 집값에 가장 강력한 영향을 미친다는 것을 확인할 수 있다.

- Lasso 모델의 Latitude(위도) 변수 축소 :

가장 특이하고 주목할 점은 Lasso 모델이 Latitude(위도) 변수의 계수를 0으로 축소시켰다는 점이다. Lasso 회귀 모델은 가중치의 절대값 합에 패널티를 부여하는 L1 규제를 사용하여 예측에 불필요하거나 중복되는 변수의 계수를 완전히 0으로 소거한다. 앞선 상관관계 분석에서 Latitude(위도)는 lon_lat_mul(위경도 곱) 변수와 -1의 상관계수를 보였다. 이를 통해 파생 변수인 lon_lat_mul(위경도 곱)이 Latitude(위도) 변수의 정보를 이미 포함하고 있어 L1 모델이 위도 변수를 소거한 것으로 확인된다.

결과적으로 지리적 상호작용을 더욱 복합적으로 설명하여 예측 모델의 효율성을 높이는 lon_lat_mul(위경도 곱) 변수만을 선택하여 유지한 것으로 해석할 수 있다.

- 규제 방식(L1 vs L2)에 따른 회귀 계수 스케일 차이 :

분석 결과 OLS와 Ridge는 회귀 계수의 스케일이 거의 일치한 반면, Lasso의 회귀 계수는 스케일이 완전히 달랐다.

이는 두 규제 알고리즘의 수학적 매커니즘 차이에서 기인한다.

L2 규제는 계수에 제곱합의 패널티를 부여하며 기하학적으로 원형의 제약 조건을 가진다. 현재 모델에서는 규제 파라미터가 매우 작아 이 원의 크기가 커져 OLS의 최적점과 거의 동일한 위치에 접점이 생기며, 이는 Ridge의 회귀 계수가 OLS의 회귀 계수와 거의 완벽하게 일치함으로써 나타났다.

반면, L1 규제는 계수에 절댓값 합의 패널티를 부여하며 기하학적으로 마름모의 형태의 제약 조건을 가진다. 현재 모델에서 규제 파라미터가 0에 수렴하기는 하나, L1 규제의 특성상 Latitude의 계수가 축에 부딪혀 정확히 0으로 소거되는 현상이 발생하였다.

이러한 현상 이후에는 모델이 예측 가중치를 효율적으로 재분배하기 위해 가중치 스케일을 재조정하며 MedInc(소득 중앙값)이 타 모델에 비해 더 높은 예측 요인이 된 이유로 확인된다.

또한 세 모델의 회귀 계수 분포를 비교한 결과, OLS와 Ridge 모델에서는 일부 지리적 변수의 계수가 6~9에 달하는 큰 스케일을 보인 반면, Lasso 모델에서는 모든 계수가 -1.5에서 1.5 사이의 좁은 범위로 압축되는 차이가 나타났다. 이는 L1 규제와 L2 규제가 다중공선성을 처리하는 본질적인 방식의 차이에서 비롯된 현상이다.

위도와 경도 그리고 이를 곱한 lon_lat_mul 변수는 서로 매우 강한 상관관계를 보인다. OLS와 Ridge에서는 이러한 중복 변수들의 오차를 상쇄하기 위해 극단적으로 계수가 커지는 풍선 효과가 발생하기 쉽다. 규제 파라미터가 0에 수렴했기 때문에 Ridge 모델에서는 계수 팽창 효과가 억제되지 않은 것으로 확인된다.

반면 L1 규제에서는 중복되는 변수를 소거하고, 이를 통해 계수가 팽창하는 현상을 억제한 것으로 확인된다. 결론적으로 Lasso 모델에서는 불필요한 위도 변수를 소거하여 이러한 풍선 효과를 효과적으로 걷어냈음을 확인할 수 있다.

OLS, Ridge 그리고 Lasso의 계수 범위의 차이는 부록 7.3에서 확인할 수 있다.

- Lasso 모델의 Trade-off :

Lasso 모델을 적용한 후 모델의 절대적 오차는 미세하게 증가하고 설명력은 미세하게 하락하였다. 이는 Latitude 변수의 계수를 소거한 후 발생한 불가피한 정보 손실 비용으로 판단된다.

반면, 평균 절대 비율 오차인 MAPE 지표는 다른 두 모델에 비해 미세하게 감소하였다. 이는 예측의 절대 오차는 미세하게 증가하였지만, 실제 집값 대비 예측 오차의 비율 측면에서의 변동성은 감소하였음을 확인할 수 있다.

- OLS vs Ridge vs Lasso :

절대적 예측 오차 측면에서는 OLS와 Ridge 모델이 우세하였으나, 정보가 완전히 겹친 변수를 제거하고 변수를 스스로 통제하는 능력을 종합적으로 고려할 때, 해당 분석에 사용된 데이터셋에서는 Lasso 모델이 가장 안정적이고 균형 잡힌 형태라 판단된다.

Lasso 모델에서는 안정적으로 회귀 계수를 압축하여 통제하였고, 이는 실제 새로운 데이터가 들어오더라도 안정적으로 예측을 할 수 있는 모델이라고 생각된다.

- 선형 모델의 한계 :


특정 핫스팟을 중심으로 하여 가격이 폭등하고, 블록에 따라 집값이 요동치는 미국 부동산 데이터의 공간적 특성상 집값은 심한 비선형적 모양을 보일 수밖에 없다. 분석에서 사용된 선형 모델들은 이러한 공간적 복잡성과 비선형성을 적절하게 학습하기에는 한계가 있다.

비선형적 및 공간적 복잡성을 적절하게 학습할 수 있는 모델을 이용한다면 예측 성능을 크게 향상시킬 것으로 생각된다.


7. 부록 (Appendix)

7.1 전처리 전 EDA


• 히스토그램



• 박스플롯



· 상관관계표




· VIF

	feature	vif
0	MedInc	11.511140
1	HouseAge	7.195917
2	AveRooms	45.993601
3	AveBedrms	43.590314
4	Population	2.935745
5	AveOccup	1.095243
6	Latitude	559.874071
7	Longitude	633.711654


- 위경도 기반 집값 분포도

california housing mapbox




7.2 전처리 후 EDA


- 히스토그램



- 박스플롯



• 상관계수




• VIF

	feature	vif
0	MedInc	21.418495
1	HouseAge	9.168768
2	AveRooms	65.127245
3	AveBedrms	99.384253
4	Population	3.212748
5	AveOccup	20.146595
6	Latitude	40620.190466
7	Longitude	3868.045743
8	lon_lat_mul	20940.851472
9	dist_to_coast	4.444678

- 위경도 기반 집값 분포


california housing mapbox



7.3 모델링 결과


· OLS 결과

	coefficient
MedInc	0.857125
HouseAge	0.092367
AveRooms	-0.147485
AveBedrms	0.077626
Population	0.023461
AveOccup	-0.259603
Latitude	6.183152
Longitude	-3.214848
lon_lat_mul	9.534636
dist_to_coast	-0.166267



· RIDGE 결과

	coefficient
MedInc	0.857131
HouseAge	0.092372
AveRooms	-0.147491
AveBedrms	0.077626
Population	0.023462
AveOccup	-0.259600
Latitude	6.179138
Longitude	-3.213733
lon_lat_mul	9.529439
dist_to_coast	-0.166256



· Lasso 결과

	coefficient
MedInc	0.865924
HouseAge	0.099107
AveRooms	-0.155025
AveBedrms	0.077794
Population	0.024659
AveOccup	-0.254582
Latitude	0.000000
Longitude	-1.495193
lon_lat_mul	1.528402
dist_to_coast	-0.150092

